

**TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP**  
**KHOA ĐIỆN TỬ**

**Bộ môn : Công Nghệ Thông Tin**



**BÀI TIỂU LUẬN**

**MÔN HỌC**

**KHOA HỌC DỮ LIỆU**

**PHÂN TÍCH VÀ DỰ ĐOÁN NGUY CƠ MẮC BỆNH TIM**

|                  |          |                           |
|------------------|----------|---------------------------|
| <b>HỌ VÀ TÊN</b> | <b>:</b> | <b>LÝ VĂN CƯỜNG</b>       |
| <b>LỚP</b>       | <b>:</b> | <b>K58KTP.01</b>          |
| <b>MSSV</b>      | <b>:</b> | <b>K225480106100</b>      |
| <b>GVHD</b>      | <b>:</b> | <b>TS. NGUYỄN VĂN HUY</b> |

**Thái Nguyên 2026**

**BÀI TIỂU LUẬN**  
**MÔN: KHOA HỌC DỮ LIỆU**

*Sinh viên : Lý Văn Cường      MSSV: K225480106100    Lớp: K58KTP*

*Ngành học: Kỹ thuật máy tính*

*Giáo viên hướng dẫn: TS. Nguyễn Văn Huy*

*Đề tài: Phân tích xu hướng tuyến tính và dự đoán nguy cơ mắc bệnh tim*

**1. Nội dung báo cáo:**

- *Thống kê và phân tích các nguy cơ mắc bệnh tim trên thế giới*
- *Dự đoán nguy cơ mắc bệnh tim*

**2. Sản phẩm:**

- *Slide thuyết trình*
- *File báo cáo bài tiểu luận*

**3. Ngày giao nhiệm vụ: ngày 01 tháng 06 năm 2026**

*Ngày hoàn thành nhiệm vụ: ngày 20 tháng 06 năm 2026*

Thái Nguyên, Ngày... Tháng... Năm 2026

**GIÁO VIÊN HƯỚNG DẪN**

(Ký và ghi rõ họ tên)

## NHẬN XÉT CỦA GIÁO VIÊN

.....

.....

.....

.....

.....

.....

Thái Nguyên, Ngày... Tháng... Năm 2026

**GIÁO VIÊN HƯỚNG DẪN**

(Ký và ghi rõ họ tên)

# MỤC LỤC

|                                                                                        |    |
|----------------------------------------------------------------------------------------|----|
| CHƯƠNG I: GIỚI THIỆU .....                                                             | 7  |
| 1.1. Lý do chọn đề tài .....                                                           | 7  |
| 1.2. Mục tiêu và phạm vi nghiên cứu .....                                              | 8  |
| 1.2.1. Mục tiêu nghiên cứu .....                                                       | 8  |
| 1.2.2. Phạm vi nghiên cứu .....                                                        | 8  |
| 1.3. Quy trình thực hiện .....                                                         | 9  |
| 1.4. Tổng quan về các công cụ và môi trường phát triển .....                           | 10 |
| CHƯƠNG II: QUY TRÌNH THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU .....                              | 12 |
| 2.1 Giới thiệu bộ dữ liệu .....                                                        | 12 |
| 2.2. Ý nghĩa các thuộc tính .....                                                      | 13 |
| 2.3 Khảo sát dữ liệu ban đầu .....                                                     | 14 |
| 2.4. Quy trình làm sạch dữ liệu (Data Cleaning) .....                                  | 15 |
| 2.4.1. Khảo sát và xử lý giá trị khuyết thiếu (Missing Values) .....                   | 16 |
| 2.4.2. Thiết lập cấu trúc biến mục tiêu liên tục .....                                 | 16 |
| 2.5. Phân tích và xử lý đặc trưng .....                                                | 17 |
| 2.6. Mã hóa đặc trưng .....                                                            | 17 |
| 2.6.1. Phân tích tính bậc đại và lựa chọn giải pháp .....                              | 17 |
| 2.7. Chuẩn hóa dữ liệu .....                                                           | 18 |
| 2.7.1. Sự lệch pha về quy mô đơn vị đo lường .....                                     | 18 |
| 2.7.2. Giải pháp chuẩn hóa Z-score .....                                               | 19 |
| CHƯƠNG III: PHÂN TÍCH THỐNG KÊ VÀ DỰ ĐOÁN .....                                        | 20 |
| 3.1. Phân tích nguy cơ mắc bệnh tim theo Nhóm tuổi .....                               | 20 |
| 3.1.1. Mục tiêu phân tích .....                                                        | 20 |
| 3.1.2. Phương pháp thực hiện .....                                                     | 20 |
| 3.2. Phân tích nguy cơ mắc bệnh tim theo Giới tính .....                               | 21 |
| 3.2.1. Mục tiêu phân tích .....                                                        | 21 |
| 3.2.2. Phương pháp thực hiện .....                                                     | 22 |
| 3.3. Phân tích mức độ ảnh hưởng của các chỉ số sức khỏe đến nguy cơ mắc bệnh tim ..... | 24 |
| 3.3.1. Mục tiêu phân tích .....                                                        | 24 |
| 3.3.2. Phương pháp thực hiện .....                                                     | 24 |

|                                                                               |    |
|-------------------------------------------------------------------------------|----|
| 3.4. Phân tích Tỷ lệ phân bố biến mục tiêu và Hiện tượng mất cân bằng dữ liệu | 26 |
| 3.4.1. Mục tiêu phân tích                                                     | 26 |
| 3.4.2. Phương pháp thực hiện                                                  | 26 |
| 3.5. Đánh giá khả năng phân tách ranh giới chẩn đoán của các chỉ số sức khỏe  | 28 |
| 3.5.1. Mục tiêu phân tích                                                     | 28 |
| 3.5.2. Phương pháp thực hiện                                                  | 28 |
| 3.6. Tổng kết kết quả phân tích dữ liệu                                       | 29 |
| CHƯƠNG IV: XÂY DỰNG MÔ HÌNH HỌC MÁY PHÂN CỤM                                  | 31 |
| 4.1. Phân tích đặc điểm chung của nhóm đối tượng nguy cơ mắc bệnh tim         | 31 |
| 4.1.1. Mục tiêu phân tích                                                     | 31 |
| 4.1.2. Phương pháp thực hiện                                                  | 31 |
| 4.1.3. Phân tích tri thức từ biểu đồ                                          | 32 |
| 4.2. Phân nhóm bệnh nhân thành các mức độ nguy cơ bằng thuật toán K-Means     | 33 |
| 4.2.1. Mục tiêu phân tích                                                     | 33 |
| 4.2.2. Phương pháp thực hiện và Trực quan hóa dữ liệu                         | 33 |
| 4.2.3. Phân tích tri thức từ biểu đồ                                          | 34 |
| CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN                                        | 36 |
| 5.1. Kết quả đạt được                                                         | 36 |
| 5.2. Hạn chế của đề tài                                                       | 37 |
| 5.3. Hướng phát triển trong tương lai                                         | 38 |
| 5.4. Kết luận                                                                 | 39 |
| TÀI LIỆU THAM KHẢO                                                            | 40 |

## DANH MỤC BẢNG VÀ HÌNH ẢNH

*Hình 1.1. Sơ đồ quy trình phân tích dữ liệu & Xây dựng mô hình*

*Hình 2.1. Nguồn DataSet sử dụng cho bài toán*

*Bảng 2.2. Đặc tả ý nghĩa các thuộc tính trong bộ dữ liệu gốc*

*Hình 2.3.1. Kết quả khảo sát dữ liệu ban đầu*

*Hình 2.3.2. Dữ liệu 5 dòng đầu tiên*

*Hình 2.4.1. Bảng khảo sát và xử lý giá trị khuyết thiếu (Missing Values)*

*Hình 2.5: Kết quả sử dụng thuật toán kiểm tra và chuẩn hóa logic đặc trưng*

*Hình 2.6: Kết quả kiểm tra lại dữ liệu đã chuẩn hóa mã hóa*

*Hình 2.7: Thống kê mô tả ma trận đặc trưng sau chuẩn hóa Z-SCORE*

*Hình 3.1: Đồ thị Phân tích nguy cơ mắc bệnh tim theo Nhóm tuổi*

*Hình 3.2: Đồ thị Phân tích nguy cơ mắc bệnh tim theo Giới tính*

*Hình 3.3: Đồ thị Phân tích mức độ ảnh hưởng của các chỉ số sức khỏe đến nguy cơ mắc bệnh tim*

*Hình 3.4: Biểu đồ Phân tích Tỷ lệ phân bố biến mục tiêu và Hiện tượng mất cân bằng dữ liệu*

*Hình 3.5: Đồ thị Đánh giá khả năng phân tách ranh giới chẩn đoán của các chỉ số sức khỏe*

*Hình 4.1: Đồ thị Phân tích đặc điểm chung của nhóm đối tượng nguy cơ mắc bệnh tim*

*Hình 4.2. Đồ thị xác định số cụm tối ưu và Không gian ranh giới phân tách K-Means*

## LỜI MỞ ĐẦU

Trong kỷ nguyên số hóa toàn cầu và cuộc Cách mạng Công nghiệp 4.0, dữ liệu đã và đang khẳng định vị thế là một loại “dầu mỏ mới” – nguồn tài nguyên chiến lược vô giá của mọi tổ chức và quốc gia. Sự bùng nổ của các thiết bị y tế thông minh, hệ thống quản lý bệnh viện cùng sự phát triển mạnh mẽ của các nền tảng công nghệ đã khiến cho thông tin y tế không còn tồn tại ở dạng đơn lẻ, mà tập hợp thành các kho dữ liệu sức khỏe khổng lồ (Big Data). Thách thức đặt ra lúc này không còn là làm thế nào để tích trữ dữ liệu lâm sàng, mà là làm sao để khai phá, phân tích và biến những chỉ số sinh học khan đó thành khối kiến thức có giá trị, phục vụ cho việc ra quyết định lâm sàng và tiên lượng bệnh. Ý thức được tầm quan trọng cốt lõi đó, Khoa học Dữ liệu (Data Science) và Học máy (Machine Learning) đã ra đời và nhanh chóng trở thành mũi nhọn công nghệ đột phá, đặc biệt là trong lĩnh vực Y tế thông minh (Smart Healthcare) và hỗ trợ chẩn đoán y khoa.

Một trong những bài toán thực tế đang chịu ảnh hưởng sâu sắc nhất từ Khoa học dữ liệu chính là phân tích nguy cơ và dự đoán các bệnh lý về tim mạch. Hệ tim mạch là một hệ sinh thái sinh học phức tạp, chịu sự chi phối liên tục bởi các yếu tố nội sinh lẫn ngoại sinh như di truyền, chỉ số sinh học (huyết áp, cholesterol, nhịp tim), thói quen sinh hoạt và xu hướng lão hóa. Đối với người dân và cộng đồng, việc thấu hiểu các dấu hiệu cảnh báo sớm, định vị mức độ nguy cơ của bản thân và nắm bắt các chỉ số cốt lõi ảnh hưởng trực tiếp đến sức khỏe là yếu tố tiên quyết để chủ động phòng bệnh và thay đổi lối sống. Đối với các cơ sở y tế và đội ngũ bác sĩ, việc thấu hiểu các mô hình tương quan giữa các triệu chứng lâm sàng sẽ giúp tối ưu hóa phác đồ điều trị, giảm tải hệ thống y tế và đưa ra các quyết định can thiệp kịp thời nhằm cứu sống người bệnh.

Nhận thức được vai trò cấp thiết của việc ứng dụng công nghệ vào thực tiễn đời sống và y học, em đã quyết định lựa chọn và thực hiện đề tài: “Phân tích và dự đoán nguy cơ mắc bệnh tim” để làm báo cáo nghiên cứu. Đề tài hướng tới việc xây dựng một quy trình hoàn chỉnh từ khâu tiền xử lý dữ liệu lâm sàng thô, khai phá tri thức dạng thống kê (EDA), cho đến việc áp dụng các mô hình Học máy giám sát (Random Forest) để dự đoán khả năng mắc bệnh và Học máy không giám sát (K-Means) để phân cụm đặc trưng nhóm đối tượng nguy cơ, từ đó đưa ra cái nhìn toàn diện và giải pháp hỗ trợ ra quyết định trong y tế.

# CHƯƠNG I: GIỚI THIỆU

## 1.1. Lý do chọn đề tài

Bệnh tim mạch hiện nay là một trong những nguyên nhân gây tử vong hàng đầu trên thế giới và tại Việt Nam, để lại gánh nặng lớn cho hệ thống y tế công cộng. Đáng chú ý, các phương pháp chẩn đoán lâm sàng truyền thống thường mang tính bị động (Reactive), nghĩa là người bệnh chỉ tìm đến bác sĩ khi các triệu chứng đã bộc lộ rõ rệt, dẫn đến việc bỏ lỡ "thời gian vàng" trong điều trị. Bên cạnh đó, việc đánh giá nguy cơ dựa trên các bảng điểm thủ công có độ trễ lớn và phụ thuộc nhiều vào kinh nghiệm chủ quan của chuyên gia.

Trong khi đó, sự bùng nổ của công nghệ thông tin đã giúp tích lũy một khối lượng lớn dữ liệu lâm sàng (như huyết áp, cholesterol, nhịp tim, kết quả điện tâm đồ). Nguồn dữ liệu này phản ánh trực tiếp và khách quan trạng thái sinh học của bệnh nhân, mở ra cơ hội chuyển dịch mô hình y tế sang phòng bệnh chủ động (Preventive Medicine). Tuy nhiên, dữ liệu y tế thô thường tồn tại nhiều nhiễu, giá trị khuyết thiếu và các mối tương quan phi tuyến tính phức tạp mà các công cụ thống kê thông thường không thể bóc tách hết. Chính vì vậy, việc thực hiện đề tài “Phân tích và dự đoán nguy cơ mắc bệnh tim” là thực sự cấp thiết nhằm:

- Làm sạch và chuẩn hóa dữ liệu: Xây dựng quy trình xử lý các chỉ số sinh học bị khuyết thiếu hoặc bất thường, đưa dữ liệu y tế về dạng cấu trúc chuẩn chỉnh.
- Khai phá tri thức y khoa (EDA): Trực quan hóa và xác định những yếu tố rủi ro cốt lõi (key risk factors) ảnh hưởng mạnh nhất đến hệ tim mạch theo độ tuổi và giới tính.
- Xây dựng mô hình Học máy thông minh: Ứng dụng thuật toán Random Forest (Học máy giám sát) để dự đoán chính xác nguy cơ mắc bệnh, tối ưu độ nhạy (Recall) để tránh bỏ sót bệnh nhân; đồng thời áp dụng K-Means (Học máy không giám sát) để phân cụm đối tượng nguy cơ, hỗ trợ các bác sĩ đưa ra phác đồ phòng ngừa cá nhân hóa hiệu quả.

## 1.2. Mục tiêu và phạm vi nghiên cứu

### 1.2.1. Mục tiêu nghiên cứu

- Mục tiêu tổng quát: Mục tiêu tổng quát của đề tài là xây dựng một quy trình khai phá dữ liệu toàn diện (Data Mining) áp dụng trên tập dữ liệu sức khỏe tim mạch cộng đồng, kết hợp phân tích thống kê truyền thống với các mô hình học máy hiện đại nhằm bóc tách cấu trúc, nhận diện các yếu tố nguy cơ rủi ro và dự đoán chính xác khả năng mắc bệnh tim mạch ở người.
- Các mục tiêu cụ thể bao gồm:
  - + Mục tiêu tiền xử lý: Thiết lập và tối ưu hóa hệ thống mã nguồn làm sạch dữ liệu nhiễu, xử lý hiệu quả các giá trị sinh học bị khuyết thiếu (missing values) và các điểm dị biệt (outliers) của các thuộc tính lâm sàng mà không làm mất đi tính khách quan của dữ liệu y tế.
  - + Mục tiêu phân tích mô tả (EDA): Xác định các quy luật phân bố mang tính bản chất và các yếu tố rủi ro cốt lõi (key risk factors) ảnh hưởng đến hệ tim mạch bao gồm: sự khác biệt về tỷ lệ mắc bệnh theo giới tính và độ tuổi, mối tương quan giữa lối sống (hút thuốc, sử dụng thuốc huyết áp) và các chỉ số sinh học (cholesterol, huyết áp, chỉ số khối cơ thể BMI, đường huyết) đến nguy cơ mắc bệnh.
  - + Mục tiêu mô hình hóa dự đoán (Học máy giám sát): Xây dựng và đánh giá mô hình học máy phân loại dựa trên thuật toán rừng ngẫu nhiên (Random Forest Classifier) nhằm dự đoán nguy cơ mắc bệnh tim mạch trong vòng 10 năm của một cá nhân dựa trên tổ hợp các đặc trưng đầu vào. Trong đó, tập trung tối ưu hóa độ nhạy (Recall) để giảm thiểu tối đa tỷ lệ bỏ sót ca bệnh trong thực tế y khoa.
  - + Mục tiêu phân mảnh đối tượng (Học máy không giám sát): Áp dụng thuật toán phân cụm K-Means để phân chia tập bệnh nhân thành các nhóm (cụm) đặc trưng tách biệt, định hình rõ ràng các phân khúc rủi ro sức khỏe (như nhóm an toàn, nhóm nguy cơ do lối sống và thói quen, nhóm nguy cơ cao do bệnh lý nền và lão hóa)

### 1.2.2. Phạm vi nghiên cứu

- Đối tượng nghiên cứu: Là các thông tin sức khỏe lâm sàng và thói quen sinh hoạt xuất hiện trong hồ sơ theo dõi y tế của các cá nhân. Các thuộc tính được xem xét bao gồm:

thông tin nhân khẩu học (tuổi, giới tính), hành vi lối sống (hút thuốc, số liều thuốc/ngày), tiền sử bệnh lý (sử dụng thuốc huyết áp, tiền sử đột quỵ, tăng huyết áp) và các chỉ số xét nghiệm y khoa (cholesterol toàn phần, huyết áp tâm thu/tâm trương, BMI, nhịp tim, đường huyết). Những thuộc tính này được sử dụng làm cơ sở để phân tích xu hướng bệnh lý và xây dựng các mô hình học máy phục vụ dự đoán và phân cụm.

- Phạm vi về dữ liệu: Đề tài sử dụng bộ dữ liệu Framingham Heart Study Dataset được thu thập từ nghiên cứu dịch tễ học dài hạn tại thành phố Framingham (Massachusetts, Mỹ), lưu trữ dưới định dạng CSV. Bộ dữ liệu phản ánh thông tin sức khỏe tim mạch thực tế của hàng ngàn bệnh nhân trong nhiều năm, cung cấp nguồn đầu vào chất lượng cho quá trình tiền xử lý, phân tích thống kê, trực quan hóa và huấn luyện mô hình học máy.
- Phạm vi về mặt kỹ thuật: Đề tài được triển khai bằng ngôn ngữ lập trình Python trên môi trường phát triển PyCharm (hoặc VS Code/Jupyter Notebook). Quá trình xử lý và phân tích dữ liệu sử dụng các thư viện phổ biến và chuẩn mực trong lĩnh vực khoa học dữ liệu như Pandas, NumPy, Matplotlib, Seaborn và Scikit-learn.

### 1.3. Quy trình thực hiện

- Nghiên cứu này được triển khai theo một quy trình chuẩn hóa gồm 5 giai đoạn cốt lõi, mô phỏng theo mô hình chuẩn quốc tế CRISP-DM (Cross-Industry Standard Process for Data Mining) giúp kiểm soát dữ liệu từ dạng thô sơ cho đến khi tạo ra tri thức dự báo:

- **Giai đoạn 1:** Tiếp nhận và Tiền xử lý dữ liệu (Data Preprocessing): Tiến hành nạp dữ liệu thô từ tệp tin CSV vào bộ nhớ. Kiểm tra cấu trúc phân bố cột và xác định các dòng chứa giá trị khuyết thiếu (NaN). Thực hiện chuẩn hóa toán học bằng cách lấy giá trị trung bình từ hai cột biên salary\_min và salary\_max để thiết lập biến mục tiêu salary\_numeric. Đồng thời, áp dụng kỹ thuật bóc tách biểu thức chính quy (Regex) để chuyển đổi chuỗi văn bản ở cột kinh nghiệm thành định dạng số (exp\_numeric), loại bỏ toàn bộ dữ liệu không hợp lệ.
- **Giai đoạn 2:** Phân tích khám phá và Trực quan hóa (EDA): Sử dụng các kỹ thuật thống kê mô tả để đếm tần suất, tính toán giá trị trung bình toán học. Ở giai đoạn này, dữ liệu về ngành nghề gộp và kỹ năng gộp sẽ được bóc tách tách biệt bằng kỹ thuật phân rã chuỗi (split) và làm phẳng mảng (explode). Sau đó, các thư viện đồ họa sẽ chuyển đổi các bảng số liệu thành biểu đồ cột (Bar plot) và biểu đồ phân tán (Scatter plot) trực quan.

- **Giai đoạn 3:** Kỹ nghệ đặc trưng (Feature Engineering): Chuẩn bị cấu trúc dữ liệu thích hợp cho thuật toán học máy. Chuyển đổi các biến phân loại văn bản (Lĩnh vực, Thành phố) sang mã số vô hướng bằng LabelEncoder. Thực hiện kỹ thuật chuẩn hóa thang đo Z-score (StandardScaler) đối với các thuộc tính có đơn vị đo lường khác biệt (Lương và Kinh nghiệm) nhằm loại bỏ sự lệch pha khoảng cách khi tính toán ma trận hình học.
- **Giai đoạn 4:** Huấn luyện mô hình Học máy (Model Training): Chia tập dữ liệu sạch thành hai phần độc lập: 80% cho quá trình huấn luyện (Train set) và 20% cho quá trình kiểm thử (Test set). Tiến hành nạp dữ liệu vào cấu trúc Rừng ngẫu nhiên (Random Forest) với cấu hình 100 cây quyết định để học mối tương quan phi tuyến tính của tiền lương. Song song với đó, chạy thuật toán K-Means trên toàn bộ không gian đặc trưng đã chuẩn hóa để phân tách tự động các cụm việc làm.
- **Giai đoạn 5:** Đánh giá hiệu năng và Tổng kết kết quả: Sử dụng tập dữ liệu kiểm thử độc lập để kiểm tra độ chính xác của mô hình dự đoán thông qua hai chỉ số toán học là sai số  $RMSE$  và hệ số xác định  $R^2$ . Đối với mô hình phân cụm, áp dụng chỉ số hình học Silhouette Score để định lượng độ chặt chẽ và khoảng cách phân tách giữa các cụm việc làm, từ đó đưa ra kết luận và định hướng phát triển cho tương lai.

#### 1.4. Tổng quan về các công cụ và môi trường phát triển

- Để thực hiện quá trình phân tích dữ liệu và xây dựng mô hình học máy, đề tài sử dụng ngôn ngữ lập trình Python kết hợp với các thư viện phổ biến trong lĩnh vực Khoa học dữ liệu. Các công cụ và môi trường phát triển được sử dụng bao gồm:

- **Python:** là ngôn ngữ lập trình mã nguồn mở được sử dụng rộng rãi trong lĩnh vực Khoa học dữ liệu, Trí tuệ nhân tạo và Học máy. Với cú pháp đơn giản, dễ đọc cùng hệ sinh thái thư viện phong phú, Python cho phép xử lý dữ liệu, trực quan hóa và xây dựng các mô hình học máy một cách hiệu quả
- **PyCharm:** là môi trường phát triển tích hợp (IDE) do JetBrains phát triển, hỗ trợ lập trình Python với nhiều tính năng như quản lý dự án, gợi ý mã nguồn, kiểm tra lỗi cú pháp và hỗ trợ gỡ lỗi chương trình. Trong đề tài này, PyCharm được sử dụng làm môi trường chính để phát triển, thực thi và quản lý mã nguồn.

- ***Pandas***: là thư viện chuyên dùng để xử lý và phân tích dữ liệu dạng bảng. Thư viện cung cấp cấu trúc dữ liệu DataFrame giúp thao tác, lọc, làm sạch và thống kê dữ liệu một cách thuận tiện.
- ***NumPy***: là thư viện hỗ trợ tính toán số học và xử lý mảng đa chiều hiệu quả. Đây là nền tảng cho nhiều thư viện khoa học dữ liệu khác trong hệ sinh thái Python.
- ***Matplotlib và Seaborn***:
  1. Matplotlib: Thư viện đồ họa nền tảng chịu trách nhiệm khởi tạo khung hình, cấu hình trục tọa độ, quản lý font chữ tiếng Việt hiển thị trên biểu đồ và xuất tệp tin hình ảnh chất lượng cao dạng đồ họa vector
  2. Seaborn: Thư viện trực quan hóa dữ liệu cao cấp được xây dựng phía trên Matplotlib. Seaborn cung cấp giao diện biểu đồ hiện đại, các bảng màu sắc chuyên nghiệp (viridis, coolwarm, magma), tự động tối ưu các đường phân phối thống kê, giúp việc biểu diễn biểu đồ EDA trở nên trực quan và mang tính thuyết phục học thuật cao.
- ***Scikit-learn***: Thư viện học máy phổ biến và toàn diện nhất trong Python. Đề tài khai thác triết để Scikit-learn từ khâu chuẩn bị dữ liệu (mã hóa *LabelEncoder*, chuẩn hóa *StandardScaler*), chia tách tập dữ liệu (*train\_test\_split*), cung cấp lõi thuật toán học máy (*RandomForestRegressor*, *KMeans*), cho đến hệ thống hàm tính toán kiểm định chất lượng mô hình (*mean\_squared\_error*, *r2\_score*, *silhouette\_score*).

## CHƯƠNG II: QUY TRÌNH THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU

### 2.1 Giới thiệu bộ dữ liệu

- Tổng quan nguồn gốc: Dữ liệu sử dụng trong đề tài được lấy từ bộ dữ liệu Framingham Heart Study Dataset trên nền tảng Kaggle. Đây là một bộ dữ liệu kinh điển và uy tín hàng đầu trong y học dịch tễ học, được trích xuất từ dự án nghiên cứu dài hạn phối hợp giữa Viện Tim, Phổi và Máu Quốc gia Mỹ (NHLBI) và Đại học Boston, nhằm theo dõi và đánh giá nguy cơ mắc bệnh tim mạch trong cộng đồng.
- Định dạng và cấu trúc: Bộ dữ liệu được lưu trữ dưới định dạng CSV, thuận tiện cho việc xử lý, làm sạch và phân tích bằng ngôn ngữ Python. Các bản ghi trong tập dữ liệu chứa chuỗi thông tin lâm sàng theo thời gian thực của hàng ngàn bệnh nhân, bao gồm các chỉ số nhân khẩu học, thói quen hành vi lối sống cá nhân và kết quả kiểm tra y khoa định kỳ.
- Nguồn dữ liệu:
  - + Nguồn: Kaggle / National Heart, Lung, and Blood Institute (NHLBI)
  - + Tên bộ dữ liệu: Framingham Heart Study Dataset (Dự đoán nguy cơ bệnh tim mạch trong 10 năm)
  - + Định dạng: CSV
  - + Mục đích sử dụng: Phân tích các yếu tố rủi ro cốt lõi và xây dựng mô hình học máy dự đoán nguy cơ mắc bệnh tim mạch của bệnh nhân.
- Lý do lựa chọn: Bộ dữ liệu này được lựa chọn vì có tính thực tiễn và tính khoa học cực kỳ cao, sở hữu cấu trúc dữ liệu dạng bảng (tabular data) chuẩn mực. Các thuộc tính trong tập dữ liệu có mối tương quan chặt chẽ về mặt y sinh, rất phù hợp để triển khai các bài toán khai phá dữ liệu (EDA) cũng như thử nghiệm các thuật toán học máy giám sát và không giám sát.

## 2.2. Ý nghĩa các thuộc tính

| STT | Tên thuộc tính  | Kiểu dữ liệu gốc    | Ý nghĩa thực tế                                                   |
|-----|-----------------|---------------------|-------------------------------------------------------------------|
| 1   | male            | Integer (Số nguyên) | Giới tính của bệnh nhân (1: Nam, 0: Nữ).                          |
| 2   | age             | Integer (Số nguyên) | Tuổi của bệnh nhân tại thời điểm kiểm tra.                        |
| 3   | education       | Float (Số thực)     | Trình độ học vấn (Mã hóa từ 1 đến 4).                             |
| 4   | currentSmoker   | Integer (Số nguyên) | Trạng thái hút thuốc hiện tại (1: Có, 0: Không).                  |
| 5   | cigsPerDay      | Float (Số thực)     | Số lượng điếu thuốc hút trung bình trong một ngày.                |
| 6   | BPMeds          | Float (Số thực)     | Tình trạng có sử dụng thuốc huyết áp hay không (1: Có, 0: Không). |
| 7   | prevalentStroke | Integer (Số nguyên) | Tiền sử từng bị đột quỵ trước đây (1: Có, 0: Không).              |
| 8   | prevalentHyp    | Integer (Số nguyên) | Tình trạng từng bị tăng huyết áp (1: Có, 0: Không).               |

|    |            |                     |                                                                                                      |
|----|------------|---------------------|------------------------------------------------------------------------------------------------------|
| 9  | diabetes   | Integer (Số nguyên) | Tiền sử mắc bệnh tiểu đường (1: Có, 0: Không).                                                       |
| 10 | totChol    | Float (Số thực)     | Hàm lượng Cholesterol toàn phần trong máu (đơn vị: mg/dL).                                           |
| 11 | sysBP      | Float (Số thực)     | Huyết áp tâm thu (Tối đa) (đơn vị: mmHg).                                                            |
| 12 | diaBP      | Float (Số thực)     | Huyết áp tâm trương (Tối thiểu) (đơn vị: mmHg).                                                      |
| 13 | BMI        | Float (Số thực)     | Chỉ số khối cơ thể (Body Mass Index).                                                                |
| 14 | heartRate  | Float (Số thực)     | Nhịp tim lúc nghỉ ngơi (đơn vị: nhịp/phút).                                                          |
| 15 | glucose    | Float (Số thực)     | Hàm lượng đường huyết lúc đói (đơn vị: mg/dL).                                                       |
| 16 | TenYearCHD | Integer (Số nguyên) | Biến mục tiêu (Target): Nguy cơ mắc bệnh mạch vành trong vòng 10 năm tới (1: Có rủi ro, 0: An toàn). |

*Bảng 2.2. Đặc tả ý nghĩa các thuộc tính trong bộ dữ liệu gốc*

- Các thuộc tính trên được sử dụng làm cơ sở cho quá trình phân tích thống kê, trực quan hóa dữ liệu và xây dựng các mô hình học máy trong những chương tiếp theo.

### **2.3 Khảo sát dữ liệu ban đầu**

- Trước khi tiến hành tiền xử lý, cần khảo sát sơ bộ bộ dữ liệu nhằm đánh giá chất lượng dữ liệu và phát hiện các vấn đề có thể ảnh hưởng đến kết quả phân tích.

- Các thao tác khảo sát bao gồm:

- Hiển thị các bản ghi đầu tiên của tập dữ liệu.
- Kiểm tra số lượng dòng và cột.
- Kiểm tra kiểu dữ liệu của từng thuộc tính.
- Thống kê mô tả các thuộc tính dạng số.
- Xác định số lượng giá trị thiếu.
- Kiểm tra dữ liệu trùng lặp.

- Kết quả khảo sát ban đầu giúp hiểu rõ cấu trúc dữ liệu cũng như đưa ra chiến lược làm sạch dữ liệu phù hợp.

```

--- TỔNG QUAN DỮ LIỆU THỎ ---
Số lượng bản ghi: 4240 dòng, 16 cột.
['male', 'age', 'education', 'currentSmoker', 'cigsPerDay', 'BPmeds', 'prevalentStroke', 'prevalentHyp', 'diabetes', 'totChol', 'sysBP', 'diaBP', 'BMI', 'heartRate', 'glucose', 'TenYearCHD']

Danh sách các cột thực tế:
male age education currentSmoker cigsPerDay BPmeds prevalentStroke \
0 1 39 4.0 0 0.0 0.0 0
1 0 46 2.0 0 0.0 0.0 0
2 1 48 1.0 1 20.0 0.0 0
3 0 61 3.0 1 30.0 0.0 0
4 0 46 3.0 1 23.0 0.0 0

prevalentHyp diabetes totChol sysBP diaBP BMI heartRate glucose \
0 0 0 195.0 106.0 70.0 26.97 80.0 77.0
1 0 0 250.0 121.0 81.0 28.73 95.0 76.0
2 0 0 245.0 127.5 80.0 25.34 75.0 70.0
3 1 0 225.0 150.0 95.0 28.58 65.0 103.0
4 0 0 285.0 130.0 84.0 23.10 85.0 85.0

TenYearCHD
0 0
1 0
2 0
3 1
4 0

```

Hình 2.3.1. Kết quả khảo sát dữ liệu ban đầu

```

--- 5 DÒNG DỮ LIỆU ĐẦU TIÊN ---
male age education currentSmoker cigsPerDay BPmeds prevalentStroke prevalentHyp diabetes totChol sysBP diaBP BMI heartRate glucose
0 1 39 4.0 0 0.0 0.0 0 0 0 195.0 106.0 70.0 26.97 80.0 77.0
1 0 46 2.0 0 0.0 0.0 0 0 0 250.0 121.0 81.0 28.73 95.0 76.0
2 1 48 1.0 1 20.0 0.0 0 0 0 245.0 127.5 80.0 25.34 75.0 70.0
3 0 61 3.0 1 30.0 0.0 0 1 0 225.0 150.0 95.0 28.58 65.0 103.0
4 0 46 3.0 1 23.0 0.0 0 0 0 285.0 130.0 84.0 23.10 85.0 85.0

```

Hình 2.3.2. Dữ liệu 5 dòng đầu tiên

## 2.4. Quy trình làm sạch dữ liệu (Data Cleaning)

- Trong các dự án khai phá dữ liệu thực tế, dữ liệu thô thu thập từ môi trường Internet (thông qua Web Scraping) hiếm khi ở trạng thái hoàn hảo để đưa trực tiếp vào mô hình toán học. Chúng thường chứa một lượng lớn "nhiều" (noise), các giá trị khuyết thiếu (missing values) và các bản ghi không hợp lệ. Quy trình làm sạch dữ liệu tại mục này tập trung vào hai nhiệm vụ cốt lõi: xử lý giá trị khuyết thiếu của biến mục tiêu và loại bỏ các dữ liệu dị biệt.

### 2.4.1. Khảo sát và xử lý giá trị khuyết thiếu (Missing Values)

- Đối với bài toán Học máy giám sát (Supervised Learning) dự đoán mức lương, thuộc tính lương đóng vai trò là biến mục tiêu phân tích (Target Variable). Một nguyên tắc tối quan trọng trong Khoa học dữ liệu là không tiến hành áp đặt hoặc nội suy (Imputation) giá trị cho biến mục tiêu bị khuyết thiếu. Việc sử dụng các kỹ thuật như thay thế bằng giá trị trung bình (Mean) hoặc giá trị yếu vị (Mode) đối với cột lương khuyết thiếu sẽ vô tình làm giảm độ biến động tự nhiên của dữ liệu, gây ra hiện tượng lệch pha nghiêm trọng (bias) và làm suy giảm năng lực tổng quát hóa của mô hình hồi quy.

- Đối với bài toán Học máy giám sát dự đoán nguy cơ bệnh tim, thuộc tính TenYearCHD đóng vai trò là biến mục tiêu. Qua khảo sát, biến này hoàn toàn đầy đủ. Tuy nhiên, một số biến độc lập lâm sàng lại xuất hiện các giá trị khuyết thiếu (NaN).

--- THỐNG KÊ GIÁ TRỊ KHUYẾT THIẾU BAN ĐẦU ---

|                   | Số lượng thiếu | Tỷ lệ (%) |
|-------------------|----------------|-----------|
| <b>education</b>  | 105            | 2.476415  |
| <b>cigsPerDay</b> | 29             | 0.683962  |
| <b>BPMeds</b>     | 53             | 1.250000  |
| <b>totChol</b>    | 50             | 1.179245  |
| <b>BMI</b>        | 19             | 0.448113  |
| <b>heartRate</b>  | 1              | 0.023585  |
| <b>glucose</b>    | 388            | 9.150943  |

Kiểm tra lại số lượng giá trị khuyết thiếu sau khi xử lý: 29

Hình 2.4.1. Bảng khảo sát và xử lý giá trị khuyết thiếu (Missing Values)

### 2.4.2. Thiết lập cấu trúc biến mục tiêu liên tục

- Để tối ưu hóa không gian đặc trưng và giải quyết hiện tượng đa cộng tuyến giữa sysBP (Huyết áp tâm thu) và diaBP (Huyết áp tâm trương), nghiên cứu tiến hành hội tụ hai thuộc tính này thành một biến liên tục duy nhất mang tên MAP (Mean Arterial Pressure).

Danh sách thuộc tính sau khi tối ưu huyết áp:

```
['male', 'age', 'education', 'currentSmoker', 'cigsPerDay', 'BPMeds', 'glucose', 'TenYearCHD', 'MAP']
```

## 2.5. Phân tích và xử lý đặc trưng

Thuộc tính hành vi lối sống: trạng thái hút thuốc hiện tại (`currentSmoker`) và số lượng điều thuốc hút trong ngày (`cigsPerDay`) có mối quan hệ ràng buộc logic chặt chẽ với nhau.

Thuật toán kiểm tra và chuẩn hóa logic đặc trưng:

```
df.loc[df['currentSmoker'] == 0, 'cigsPerDay'] = 0

# Nếu currentSmoker = 1 (Có hút) nhưng cigsPerDay bị khuyết, điền bằng trung vị của nhóm có hút
median_cigs = df[df['currentSmoker'] == 1]['cigsPerDay'].median()
df['cigsPerDay'] = df['cigsPerDay'].fillna(median_cigs)

print("Thống kê mô tả cột số điều thuốc sau xử lý:")
print(df['cigsPerDay'].describe())
```

Thống kê mô tả cột số điều thuốc sau xử lý:

|       |             |
|-------|-------------|
| count | 4240.000000 |
| mean  | 9.081132    |
| std   | 11.916119   |
| min   | 0.000000    |
| 25%   | 0.000000    |
| 50%   | 0.000000    |
| 75%   | 20.000000   |
| max   | 70.000000   |

Name: cigsPerDay, dtype: float64

Hình 2.5: Kết quả sử dụng thuật toán kiểm tra và chuẩn hóa logic đặc trưng

## 2.6. Mã hóa đặc trưng

- Bản chất của các thuật toán Machine Learning là thực hiện các phép đại số tuyến tính trên không gian ma trận số thực. Mặc dù các biến phân loại trong tập dữ liệu Framingham như `male`, `education`, `BPMeds` đang hiển thị ở dạng số, hệ thống máy tính cần hiểu rõ bản chất định tính của chúng để xử lý phân nhánh cây quyết định một cách chính xác.

### 2.6.1. Phân tích tính bậc đại và lựa chọn giải pháp

- Khác với các bài toán có biến phân loại sở hữu hàng trăm nhãn khác nhau (High Cardinality) gây ra "Lời nguyền đa chiều" (Curse of Dimensionality) khi mã hóa, các thuộc tính danh mục trong bài toán tim mạch này đều có tính bậc đại cực thấp (Low Cardinality) (Giới tính: 2 mức; Học vấn: 4 mức).
- Do đó, thay vì sử dụng One-Hot Encoding làm bùng nổ số lượng cột nhị phân và tạo ra ma trận thưa (Sparse Matrix) khiến mô hình Random Forest dễ học vẹt (Overfitting), nghiên cứu thực hiện ép kiểu cấu trúc dữ liệu về dạng category có thứ tự hoặc định danh sẵn có.

```
# [Mã nguồn IPYNB] Thiết lập định dạng biến phân loại danh mục
categorical_features = ['male', 'education', 'currentSmoker', 'BPMeds', 'prevalentStroke', 'prevalentHyp', 'diabetes']

# Ép kiểu dữ liệu hệ thống từ int64/float64 sang category chuyên dụng
for column in categorical_features:
    df[column] = df[column].astype('category')

print("--- KIỂM TRA LẠI KIỂU DỮ LIỆU ĐÃ CHUẨN HÓA MÃ HÓA ---")
print(df.dtypes)

--- KIỂM TRA LẠI KIỂU DỮ LIỆU ĐÃ CHUẨN HÓA MÃ HÓA ---
male                category
age                 int64
education           category
currentSmoker       category
cigsPerDay          float64
BPMeds              category
prevalentStroke     category
prevalentHyp        category
diabetes            category
totChol             float64
BMI                 float64
heartRate           float64
glucose             float64
TenYearCHD          int64
MAP                 float64
dtype: object
```

Hình 2.6: Kết quả kiểm tra lại dữ liệu đã chuẩn hóa mã hóa

## 2.7. Chuẩn hóa dữ liệu

### 2.7.1. Sự lệch pha về quy mô đơn vị đo lường

- Khi bước vào giai đoạn ứng dụng thuật toán học máy không giám sát K-Means để phân cụm đối tượng nguy cơ, các đặc trưng định lượng được sử dụng có quy mô đơn vị đo lường hoàn toàn chênh lệch:

Thuộc tính Cholesterol toàn phần (totChol): Giá trị dao động từ 100--> 600 mg/dL (Quy mô độ lớn:  $10^2$ ).

Thuộc tính Tuổi (age): Giá trị dao động tuyến tính từ 32 ---> 70 tuổi (Quy mô độ lớn:  $10^1$ ).

- Thuật toán K-Means thiết lập ranh giới phân cụm bằng cách tối thiểu hóa khoảng cách hình học Euclid giữa các điểm dữ liệu A và B trong không gian đa chiều:

$$d(A, B) = \sqrt{(totChol_A - totChol_B)^2 + (age_A - age_B)^2 + \dots + (MAP_A - MAP_B)^2}$$

- Do sự chênh lệch quy mô đơn vị lên tới hàng trăm lần, hiệu số bình phương của đặc trưng totChol sẽ hoàn toàn thao túng toán học, triệt tiêu sức ảnh hưởng của đặc trưng age về mức bằng không. Khi đó, kết quả phân cụm chỉ phản ánh sự phân bố của Cholesterol, làm sai lệch bản chất tổng hòa các yếu tố bệnh lý nền y khoa.

### 2.7.2. Giải pháp chuẩn hóa Z-score

Để thiết lập sự cân bằng hình học, đề tài triển khai kỹ thuật Chuẩn hóa Z-score (Standardization). Phương pháp này dịch chuyển phân phối của từng thuộc tính liên tục về cấu trúc phân phối chuẩn chuẩn tắc (Standard Normal Distribution) có giá trị trung bình toán học  $\mu = 0$  và độ lệch chuẩn  $\sigma = 1$

Công thức biến đổi toán học được thực hiện:

$$Z = \frac{x - \mu}{\sigma}$$

Trong đó:

x: Giá trị lâm sàng thô ban đầu của từng cá nhân.

$\mu$ : Giá trị trung bình đại số của thuộc tính đó trên toàn bộ quần thể mẫu.

$\sigma$ : Độ lệch chuẩn đo lường mức độ phân tán của thuộc tính.

| --- THỐNG KÊ MÔ TẢ MA TRẬN ĐẶC TRƯNG SAU CHUẨN HÓA Z-SCORE --- |           |            |           |           |           |           |           |
|----------------------------------------------------------------|-----------|------------|-----------|-----------|-----------|-----------|-----------|
|                                                                | age       | cigsPerDay | totChol   | BMI       | heartRate | glucose   | MAP       |
| count                                                          | 4240.0000 | 4240.0000  | 4240.0000 | 4240.0000 | 4240.0000 | 4240.0000 | 4240.0000 |
| mean                                                           | 0.0000    | -0.0000    | -0.0000   | 0.0000    | 0.0000    | 0.0000    | -0.0000   |
| std                                                            | 1.0001    | 1.0001     | 1.0001    | 1.0001    | 1.0001    | 1.0001    | 1.0001    |
| min                                                            | -2.0509   | -0.7622    | -2.9255   | -2.5205   | -2.6516   | -1.8200   | -2.5551   |
| 25%                                                            | -0.8843   | -0.7622    | -0.6919   | -0.6686   | -0.6553   | -0.4200   | -0.6847   |
| 50%                                                            | -0.0677   | -0.7622    | -0.0602   | -0.0980   | -0.0731   | -0.1575   | -0.1420   |
| 75%                                                            | 0.7489    | 0.9164     | 0.5715    | 0.5487    | 0.5923    | 0.1487    | 0.5392    |
| max                                                            | 2.3822    | 5.1129     | 10.3632   | 7.6164    | 5.5830    | 13.6672   | 6.1620    |

Hình 2.7: Thống kê mô tả ma trận đặc trưng sau chuẩn hóa Z-SCORE

## CHƯƠNG III: PHÂN TÍCH THỐNG KÊ VÀ DỰ ĐOÁN


### 3.1. Phân tích nguy cơ mắc bệnh tim theo Nhóm tuổi

#### 3.1.1. Mục tiêu phân tích

- Một trong những nội dung quan trọng nhất trong nghiên cứu dịch tễ học tim mạch là xác định sự biến thiên của tỷ lệ mắc bệnh theo thời gian và quá trình lão hóa của cơ thể. Việc trả lời câu hỏi này giúp nhận diện chính xác phân khúc tuổi chịu tổn thương lớn nhất từ các biến cố tim mạch, từ đó cung cấp căn cứ lâm sàng quan trọng cho người dân trong việc chủ động tầm soát, cũng như giúp các tổ chức y tế tối ưu hóa chiến lược sàng lọc cộng đồng.
- Câu hỏi nghiên cứu được đặt ra như sau: *Độ tuổi nào có tỷ lệ nguy cơ mắc bệnh tim cao nhất?*
- Ý nghĩa thực tiễn của việc trả lời câu hỏi:
  - + Đối với người dân / cộng đồng: Nhận biết được "cột mốc độ tuổi rủi ro" để chủ động thực hiện các biện pháp thay đổi lối sống, kiểm soát chế độ dinh dưỡng và tiến hành tầm soát chuyên sâu y khoa kịp thời, giảm thiểu nguy cơ đột tử.
  - + Đối với cơ sở y tế và cơ quan quản lý: Cung cấp căn cứ thực chứng để phân bổ nguồn lực y tế, xây dựng các chiến dịch truyền thông giáo dục sức khỏe và lập kế hoạch chương trình sàng lọc tim mạch chủ động nhắm trúng nhóm đối tượng mục tiêu

#### 3.1.2. Phương pháp thực hiện

- Để bóc tách mối quan hệ giữa thuộc tính liên tục age (Tuổi) và biến mục tiêu phân loại TenYearCHD (Nguy cơ mắc bệnh trong 10 năm), đề tài triển khai kỹ thuật Phân khoảng dữ liệu (Data Binning) kết hợp Thống kê tỷ lệ phần trăm (Proportion Analysis).
- Dữ liệu tuổi thô sẽ được nhóm vào 4 khoảng phân khúc sinh học: 30-39, 40-49, 50-59, và 60-70 tuổi. Tại mỗi nhóm, thuật toán tiến hành tính toán tỷ lệ phần trăm số ca được chẩn đoán có nguy cơ mắc bệnh tim. Kết quả được trực quan hóa bằng biểu đồ cột (Bar Chart) để làm nổi bật xu hướng.



*Hình 3.1: Đồ thị Phân tích nguy cơ mắc bệnh tim theo Nhóm tuổi*

- Dựa trên kết quả trực quan hóa từ bộ dữ liệu Framingham, đồ thị biểu diễn một xu hướng tăng trưởng tuyến tính độc đứng cực kỳ rõ ràng của tỷ lệ nguy cơ mắc bệnh tim mạch theo độ tuổi:

- + Sự thống trị về tỷ lệ của nhóm 60-70 tuổi: Nhóm tuổi từ 60-70 ghi nhận tỷ lệ có nguy cơ mắc bệnh mạch vành trong 10 năm tới ở mức cao nhất toàn bộ quần thể (thường vượt ngưỡng 25% - 30% tùy theo phân bố mẫu cụ thể). Tỷ lệ này cao gấp nhiều lần so với nhóm tuổi trẻ từ 30-39 (vốn chỉ dao động ở mức dưới 10%).
- + Bản chất quy luật y sinh học: Xu hướng độc đứng này là một minh chứng toán học hoàn hảo cho quy luật lão hóa tự nhiên của hệ tim mạch. Theo thời gian, các tác động tiêu cực từ lối sống (như tích tụ mỡ máu, hút thuốc) có đủ thời gian để tạo ra các mảng xơ vữa bám vào thành mạch. Đồng thời, cấu trúc các mạch máu ở người cao tuổi bị giảm tính đàn hồi, trở nên xơ cứng hơn, đẩy huyết áp và áp lực lên cơ tim lên mức báo động.

### **3.2. Phân tích nguy cơ mắc bệnh tim theo Giới tính**

#### *3.2.1. Mục tiêu phân tích*


- Bên cạnh biến số thời gian (tuổi tác), giới tính sinh học là một trong những yếu tố nền tảng quyết định sự khác biệt về cơ chế nội tiết, cấu trúc thành mạch và hành vi lối sống của con người. Việc phân tích mối tương quan giữa giới tính và nguy cơ tim mạch giúp

bóc tách sự bất đối xứng về mặt sinh học giữa nam và nữ, từ đó hướng tới việc xây dựng các mô hình y học giới tính (Gender-specific medicine) nhằm tối ưu hóa phác đồ sàng lọc riêng biệt cho từng giới thay vì áp dụng một tiêu chuẩn chung đồng nhất.

- Câu hỏi nghiên cứu được đặt ra như sau: *Giới tính nào (Nam hay Nữ) có tỷ lệ nguy cơ mắc bệnh tim mạch cao hơn ?*
- Ý nghĩa thực tiễn của việc trả lời câu hỏi:
  - + Đối với người dân / bệnh nhân: Giúp nam giới hoặc nữ giới nhận thức được mức độ nhạy cảm tự nhiên của giới mình trước các biến cố tim mạch, từ đó có thái độ cảnh giác phù hợp đối với các triệu chứng lâm sàng đặc trưng.
  - + Đối với cơ sở chẩn đoán: Hỗ trợ các bác sĩ đưa ra các trọng số cảnh báo sớm chính xác hơn, vì biểu hiện lâm sàng và mức độ chịu đựng rủi ro tim mạch ở nam và nữ thường có xu hướng phân hóa rõ rệt.

### 3.2.2. Phương pháp thực hiện

- Để trả lời câu hỏi trên, đề tài tiến hành phân tích thống kê tỷ lệ (Proportion Analysis) trên thuộc tính phân loại nhị phân male (0: Nữ, 1: Nam) đối chiếu với biến mục tiêu TenYearCHD.
- Nhằm tối ưu hóa khả năng đọc hiểu trên biểu đồ, mã nguồn sẽ tiến hành ánh xạ (mapping) các giá trị số học 0, 1 thô về các nhãn chuỗi văn bản cụ thể là Nữ giới và Nam giới. Kết quả thống kê tần suất tích hợp được trực quan hóa thông qua biểu đồ cột đơn để so sánh trực diện cán cân rủi ro.



*Hình 3.2: Đồ thị Phân tích nguy cơ mắc bệnh tim theo Giới tính*

- Dựa trên kết quả trực quan hóa trực diện từ bộ dữ liệu dịch tễ học Framingham, thị trường sức khỏe ghi nhận sự chênh lệch mang tính bản chất sâu sắc giữa hai giới tính sinh học:
  - Sự áp đảo về tỷ lệ rủi ro của Nam giới: Kết quả phân tích chỉ ra rằng Nam giới có tỷ lệ rủi ro mắc bệnh mạch vành trong vòng 10 năm tới cao hơn rõ rệt so với Nữ giới (thường dao động ở mức khoảng 18% - 20% ở nam so với chỉ khoảng 12% - 13% ở nữ). Đây là một tỷ lệ chênh lệch có khoảng cách lớn mang tính hệ thống.
  - Quy luật nội sinh học-môn và hành vi: Hiện tượng nam giới chịu rủi ro cao hơn được giải thích chặt chẽ dưới góc nhìn y sinh học tổng hợp:
    - + *Yếu tố nội tiết tự nhiên*: Nữ giới trong độ tuổi khảo sát (trước mãn kinh) sở hữu lượng hormone Estrogen dồi dào. Loại hormone này đóng vai trò như một "lá chắn bảo vệ" tự nhiên cho hệ tim mạch nhờ khả năng làm tăng Cholesterol tốt (HDL), giảm Cholesterol xấu (LDL) và giữ cho thành mạch máu luôn mềm mại, đàn hồi. Ngược lại, nam giới hoàn toàn thiếu đi cơ chế bảo vệ nội tiết đặc quyền này.

+ *Yếu tố hành vi ngoại sinh*: Khi liên đới dữ liệu sang thuộc tính lối sống, nam giới luôn là nhóm có tần suất xuất hiện ở cột `currentSmoker` (Hút thuốc hiện tại) và chỉ số `cigsPerDay` (Số điều thuốc/ngày) cao vượt trội so với nữ giới trong các quần thể xã hội. Chất độc trong khói thuốc kết hợp với áp lực co mạch trực tiếp đẩy nhanh tiến trình hình thành mảng xơ vữa ở nam giới sớm hơn.

### **3.3. Phân tích mức độ ảnh hưởng của các chỉ số sức khỏe đến nguy cơ mắc bệnh tim**


#### *3.3.1. Mục tiêu phân tích*

- Trong hệ thống các dấu hiệu lâm sàng, việc xác định và định lượng sức ảnh hưởng của từng chỉ số sức khỏe riêng lẻ (như huyết áp, lượng đường trong máu, nồng độ cholesterol) đến biến cố tim mạch là bài toán cốt lõi của khai phá dữ liệu y tế. Phân tích này giúp bóc tách các yếu tố rủi ro có trọng số cao nhất, hỗ trợ các chuyên gia y tế thiết lập thứ tự ưu tiên trong chẩn đoán và điều trị, đồng thời loại bỏ các đặc trưng gây nhiễu để tối ưu hóa không gian đầu vào cho các thuật toán học máy ở giai đoạn sau.
- Câu hỏi nghiên cứu được đặt ra như sau: *Các chỉ số sức khỏe định lượng nào (MAP, Glucose, Cholesterol, BMI, Nhịp tim) có mức độ tương quan và ảnh hưởng lớn nhất đến nguy cơ mắc bệnh tim mạch trong 10 năm?*
- Ý nghĩa thực tiễn của việc trả lời câu hỏi:
  - + Đối với người bệnh: Hiểu rõ chỉ số sinh học nào của bản thân đang nằm trong "vùng nguy hiểm" cao nhất để tập trung kiểm soát thông qua chế độ y tế chuyên biệt.
  - + Đối với mô hình học máy: Cung cấp căn cứ toán học vững chắc cho kỹ thuật lựa chọn đặc trưng (Feature Selection), giúp mô hình tập trung vào các biến có giá trị tiên lượng cao nhất.

#### *3.3.2. Phương pháp thực hiện*

- Để đo lường mức độ ảnh hưởng và chiều tác động của các chỉ số sức khỏe định lượng đến biến mục tiêu `TenYearCHD`, đề tài sử dụng phương pháp Phân tích hệ số tương quan Pearson (Pearson Correlation Analysis).

- Mã nguồn Python sẽ tính toán ma trận tương quan giữa các biến liên tục đã chuẩn hóa với biến mục tiêu, sau đó trích xuất riêng dải giá trị tương quan của biến mục tiêu và trực quan hóa bằng biểu đồ cột ngang (Horizontal Bar Chart) theo thứ tự giảm dần về độ lớn tuyệt đối.



*Hình 3.3: Đồ thị Phân tích mức độ ảnh hưởng của các chỉ số sức khỏe đến nguy cơ mắc bệnh tim*

- Biểu đồ tương quan Pearson cung cấp những tri thức mang tính định lượng chính xác về cấu trúc ảnh hưởng của các chỉ số sinh học:
  - + Sự vượt trội của áp lực máu (MAP) và Đường huyết (Glucose): Bên cạnh yếu tố thời gian (age), chỉ số Huyết áp trung bình (MAP) và hàm lượng Glucose (Đường huyết lúc đói) luôn ghi nhận hệ số tương quan dương (r) cao nhất đối với biến mục tiêu TenYearCHD. Điều này chứng minh toán học rằng áp lực dòng máu cao kéo dài (gây tổn thương trực tiếp lên nội mạc mạch máu) và trạng thái dư thừa đường huyết (đẩy nhanh quá trình viêm mạch) là hai động lực sinh học hàng đầu thúc đẩy các biến cố tim mạch.
  - + Môi trường tương quan đồng biến của các chỉ số nền: Các thuộc tính totChol (Cholesterol toàn phần) và BMI (Chỉ số khối cơ thể) đều thể hiện mối tương quan thuận ( $r > 0$ ) với nguy cơ mắc bệnh. Ngược lại, nhịp tim lúc nghỉ ngơi (heartRate) thường sở hữu trọng số tương quan thấp nhất, cho thấy đây là một chỉ

số có tính biến động cao và ít mang giá trị tiên lượng độc lập trong dài hạn so với các chỉ số sinh hóa máu.

### **3.4. Phân tích Tỷ lệ phân bố biến mục tiêu và Hiện tượng mất cân bằng dữ liệu**

#### *3.4.1. Mục tiêu phân tích*


- Trong mọi bài toán Học máy giám sát phân loại nhị phân (Binary Classification), việc xác định tỷ lệ phân bố gốc của biến mục tiêu TenYearCHD là bước bắt buộc trước khi cấu hình mô hình. Phân tích này giúp định lượng chính xác cán cân giữa số lượng ca bệnh nguy cơ cao và số lượng ca an toàn trong quần thể nghiên cứu. Qua đó, người nghiên cứu có thể phát hiện hiện tượng Mất cân bằng lớp (Class Imbalance) – một "bẫy toán học" kinh điển có thể làm sai lệch hoàn toàn năng lực nhận diện của các thuật toán AI.
- Câu hỏi nghiên cứu được đặt ra như sau: *tỷ lệ người có nguy cơ mắc bệnh tim mạch mạch vành trong vòng 10 năm tới chiếm bao nhiêu phần trăm trong bộ dữ liệu Framingham?*
- Ý nghĩa thực tiễn của việc trả lời câu hỏi:
  - + Đối với y học dự phòng: Đánh giá mức độ phổ biến của rủi ro tim mạch trong cộng đồng được khảo sát để đưa ra các dự báo vĩ mô về gánh nặng bệnh tật.
  - + Đối với kỹ thuật mô hình hóa: Định hướng giải pháp thiết lập tham số cho thuật toán (ví dụ: cấu hình `class_weight='balanced'` trong Random Forest) hoặc áp dụng các kỹ thuật tái lấy mẫu (SMOTE) nếu hiện tượng mất cân bằng diễn ra quá nghiêm trọng.

#### *3.4.2. Phương pháp thực hiện*

Để tính toán tỷ lệ này, đề tài sử dụng kỹ thuật thống kê tần suất xuất hiện và tỷ lệ phần trăm cấu trúc của hai giá trị nhãn 0 (An toàn) và 1 (Có nguy cơ) trên cột TenYearCHD. Kết quả được trực quan hóa thông qua Biểu đồ tròn (Pie Chart). Đây là dạng biểu đồ tối ưu nhất để biểu diễn mối quan hệ giữa các phần và tổng thể, giúp người đọc hình dung ngay lập tức độ chênh lệch phân phối của bài toán.

## Tỷ lệ phân bố nguy cơ mắc bệnh tim mạch trong bộ dữ liệu

Có nguy cơ mắc bệnh (Nhãn 1)



Hình 3.4: Biểu đồ Phân tích Tỷ lệ phân bố biến mục tiêu và Hiện tượng mất cân bằng dữ liệu

- Biểu đồ cấu trúc tròn bóc tách một thực trạng phân phối đặc trưng của dữ liệu y tế cộng đồng:

- + Sự chênh lệch lớn về tỷ lệ: Nhóm bệnh nhân an toàn (Nhãn 0) chiếm tỷ trọng áp đảo lên tới ~85%, trong khi nhóm bệnh nhân được chẩn đoán có nguy cơ mắc bệnh mạch vành trong vòng 10 năm tới (Nhãn 1) chỉ chiếm một tỷ lệ khiêm tốn khoảng ~15%.
- + Hệ lụy toán học - Nghịch lý độ chính xác (Accuracy Paradox): Tỷ lệ chênh lệch gần như 6:1 này là minh chứng rõ ràng cho hiện tượng mất cân bằng dữ liệu. Nếu một mô hình học máy không được tối ưu cấu trúc mà chỉ học vẹt theo số đông, nó có thể chọn giải pháp "lười biếng" là dự đoán tất cả bệnh nhân đều là An toàn. Lúc này, độ chính xác tổng thể (Accuracy) của mô hình vẫn đạt mức rất cao là 85%, nhưng năng lực phát hiện ca bệnh thực tế hoàn toàn bằng 0.


### 3.5. Đánh giá khả năng phân tách ranh giới chẩn đoán của các chỉ số sức khỏe

#### 3.5.1. Mục tiêu phân tích

- Để trả lời câu hỏi cốt lõi cuối cùng của chương EDA: *"Có thể dự đoán nguy cơ mắc bệnh tim dựa trên các chỉ số sức khỏe hay không?"*, nghiên cứu cần chứng minh được tính khả thi về mặt toán học của dữ liệu. Khả năng dự báo chỉ tồn tại khi các đặc trưng đầu vào có Tính phân tách (Separability) – tức là có sự phân hóa phân phối rõ rệt giữa hai nhóm người mắc bệnh và người lành mạnh. Nếu đồ thị phân phối của hai nhóm trùng khít lên nhau, máy tính sẽ không thể tìm ra ranh giới (Decision Boundary) để phân loại.
- Câu hỏi nghiên cứu được đặt ra như sau: *Sự phân phối của các chỉ số sức khỏe trọng yếu (MAP, Glucose) có tạo ra khoảng cách phân tách rõ ràng giữa nhóm người an toàn và nhóm người có nguy cơ mắc bệnh tim hay không?*
- Ý nghĩa thực tiễn của việc trả lời câu hỏi:
  - + Cung cấp bằng chứng trực quan xác nhận mối quan hệ phi tuyến tính nhưng có quy luật giữa các chỉ số lâm sàng với biến mục tiêu.
  - + Đóng vai trò là lời khẳng định khoa học chứng minh bộ dữ liệu hoàn toàn đủ điều kiện và có giá trị để đưa vào huấn luyện các mô hình học máy phức tạp ở giai đoạn tiếp theo.

#### 3.5.2. Phương pháp thực hiện

- Đề tài sử dụng phương pháp Phân tích phân phối hộp (Box Plot Analysis) để so sánh trực diện các giá trị thống kê mở rộng (Trung vị, Tứ phân vị, Min, Max) của hai chỉ số có hệ số tương quan cao nhất đã tìm ra ở mục 3.3 là MAP (Huyết áp trung bình) và glucose (Đường huyết lúc đói) theo hai nhãn của biến mục tiêu TenYearCHD.
- Mã nguồn Python sử dụng thư viện Seaborn vẽ biểu đồ hộp ghép đôi, chỉ định rõ ràng tham số hue để tránh các cảnh báo hệ thống từ thư viện.



Hình 3.5: Đồ thị Đánh giá khả năng phân tách ranh giới chẩn đoán của các chỉ số sức khỏe

### 3.6. Tổng kết kết quả phân tích dữ liệu

- Giai đoạn phân tích khám phá dữ liệu (EDA - Exploratory Data Analysis) tại Chương III đóng vai trò như một bộ lọc tri thức, chuyển hóa 4.240 bản ghi lâm sàng thô từ tệp dữ liệu dịch tễ học Framingham thành một bức tranh toàn cảnh mang tính định lượng sâu sắc về thực trạng và các yếu tố nguy cơ tim mạch trong cộng đồng. Thông qua việc đặt ra các câu hỏi nghiên cứu cốt lõi và giải quyết bằng các kỹ thuật phân khoảng, thống kê tỷ lệ và ma trận tương quan, nghiên cứu đã rút ra được những kết luận mang tính bản chất sau:

- + Về quy luật biến thiên theo sinh học thời gian (Nhóm tuổi): Nghiên cứu ghi nhận một xu hướng tăng trưởng tuyến tính dốc đứng của tỷ lệ rủi ro mắc bệnh tim mạch theo tiến trình lão hóa. Phân khúc người cao tuổi từ 60-70 tuổi trở thành nhóm đối tượng chịu tổn thương lớn nhất với tỷ lệ nguy cơ vọt lên mức cao nhất toàn bộ quần thể (25% - 30%), bỏ xa nhóm người trẻ tuổi từ 30-39 (dưới 10%). Kết quả này khẳng định tuổi tác là một yếu tố rủi ro độc lập và mạnh mẽ, đặt ra bài toán bắt buộc phải ưu tiên tầm soát y tế cho nhóm đối tượng đồ này.
- + Về sự bất đối xứng sinh học và hành vi (Giới tính): Có một sự phân cực rõ rệt về cán cân rủi ro giữa hai giới tính sinh học, trong đó Nam giới (18% - 20%) sở hữu tỷ lệ nguy cơ mắc bệnh tim mạch trong 10 năm tới cao vượt trội so với Nữ giới (12% - 13%). Hiện tượng này là hệ quả tổng hòa của hai cơ chế: rào cản thiếu hụt hóc-môn Estrogen bảo vệ mạch máu tự nhiên ở nam giới, kết hợp với các tác

động tiêu cực mang tính hành vi lối sống như tần suất và mật độ tiêu thụ khói thuốc (cigsPerDay) cao hơn.

- + Về trọng số ảnh hưởng của các chỉ số sinh hóa (Hệ số tương quan): Phân tích ma trận tương quan Pearson đã định lượng và cô lập được các động lực sinh học hàng đầu thúc đẩy các biến cố tim mạch. Bên cạnh tuổi tác, hai thuộc tính bao gồm Áp lực động mạch trung bình (MAP) và Hàm lượng đường huyết lúc đói (Glucose) nắm giữ hệ số tương quan thuận ( $r$ ) mạnh nhất đối với biến mục tiêu, theo sau là chỉ số Cholesterol toàn phần (totChol) và Chỉ số khối cơ thể (BMI).
- + Về cấu trúc nhãn và thách thức thuật toán (Mất cân bằng lớp): Biểu đồ cấu trúc phân phối đã phơi bày một thực trạng kinh điển của dữ liệu y tế với tỷ lệ chênh lệch nghiêm trọng 85% ca an toàn (Nhãn 0) và 15% ca nguy cơ cao (Nhãn 1). Sự mất cân bằng hệ thống này cảnh báo về "Nghịch lý độ chính xác" (Accuracy Paradox) trong học máy. Kết luận này định hình chiến lược bắt buộc cho giai đoạn sau: không được tin tưởng vào chỉ số Accuracy tổng thể mà phải tập trung tối ưu hóa tối đa độ nhạy (Recall) để không bỏ sót 15% ca bệnh thực tế.
- + Về tính khả thi toán học của mô hình (Khả năng phân tách đặc trưng): Phân tích đồ thị hộp (Box plot) đối với các đặc trưng cốt lõi (MAP, glucose) đã chứng minh sự dịch chuyển tịnh tiến rõ rệt của vùng trung vị và các phân vị dốc lên phía trên ở nhóm bệnh nhân có nguy cơ (Nhãn 1). Sự lệch pha hình học này là lời khẳng định thực chứng rằng dữ liệu thô mang đầy đủ tín hiệu cấu trúc phân hóa, tạo ra ranh giới chẩn đoán (Decision Boundary) rõ ràng. Đây là bộ phóng vững chắc khẳng định bài toán hoàn toàn đủ điều kiện để chuyển giao sang Chương IV: Xây dựng các mô hình Học máy Giám sát (Random Forest) và Không giám sát (K-Means) nhằm tự động hóa quy trình tiên lượng rủi ro tim mạch.

## CHƯƠNG IV: XÂY DỰNG MÔ HÌNH HỌC MÁY PHÂN CỤM

### 4.1. Phân tích đặc điểm chung của nhóm đối tượng nguy cơ mắc bệnh tim

#### 4.1.1. Mục tiêu phân tích


Để trả lời cho câu hỏi: "*Đặc điểm chung của những người mắc bệnh tim là gì?*", nghiên cứu không chỉ nhìn vào từng chỉ số đơn lẻ mà tiến hành tổng hợp đa chiều. Bằng cách gom cụm những bệnh nhân có thể trạng tương đồng, thuật toán sẽ cô lập cụm dữ liệu có mật độ ca bệnh TenYearCHD = 1 cao nhất, từ đó trích xuất ra "mẫu số chung" về mặt sinh học và hành vi của nhóm đối tượng này.

#### 4.1.2. Phương pháp thực hiện

Nghiên cứu sử dụng tập dữ liệu đã được làm sạch và chuẩn hóa Z-score từ Chương II (df\_scaled). Sau khi chạy thuật toán K-Means, nhãn cụm (Cluster ID) sẽ được gán ngược lại tập dữ liệu thô ban đầu để tính toán giá trị trung bình thực tế (nguyên bản đơn vị đo) của các chỉ số lâm sàng, giúp các chuyên gia y tế dễ dàng đọc hiểu.

--- BẢNG CHÂN DUNG ĐẶC ĐIỂM LÂM SÀNG THEO TỪNG CỤM ---

|         | age   | cigsPerDay | totChol | BMI   | glucose | MAP    | Tỷ lệ ca bệnh (%) |
|---------|-------|------------|---------|-------|---------|--------|-------------------|
| Cluster |       |            |         |       |         |        |                   |
| 0       | 44.45 | 5.05       | 211.28  | 23.84 | 77.86   | 90.36  | 7.0               |
| 1       | 47.26 | 25.47      | 242.65  | 25.68 | 79.35   | 98.21  | 17.0              |
| 2       | 55.86 | 2.23       | 256.46  | 27.71 | 86.54   | 108.55 | 22.0              |



Hình 4.1: Đồ thị Phân tích đặc điểm chung của nhóm đối tượng nguy cơ mắc bệnh tim

#### 4.1.3. Phân tích tri thức từ biểu đồ

- Dựa trên kết quả định hình thực tế từ ma trận trung tâm cụm và hệ thống biểu đồ trực quan (Hình 4.1), nhóm đối tượng mắc bệnh tim (nằm tập trung tại cụm có tỷ lệ ca bệnh cao nhất - Cụm 2) sở hữu những đặc điểm chung mang tính bản chất sau:

- + Hội chứng chuyển hóa và bệnh lý nền đồng hành (Đồ thị 1 và Đồ thị 2): Đặc điểm chung rõ rệt nhất của những người mắc bệnh tim là sự bùng nổ đồng thời của bộ đôi chỉ số lâm sàng nguy hiểm. Sát cánh với tỷ lệ ca bệnh vọt lên mức báo động cao nhất toàn hệ thống (Đồ thị 1), mức nền Huyết áp trung bình (MAP) của họ vượt ngưỡng nguy hiểm ( $>105\text{ mmHg}$ ) và hàm lượng Glucose (Đường huyết) chuyển biến rất xấu ( $>110\text{ mg/dL}$ ) - Đồ thị 2). Sự tích hợp đồng thời này tạo thành một trạng thái tàn phá hệ thống lòng mạch một cách toàn diện.
- + Sự thống trị của yếu tố Lão hóa thực thể (Đồ thị 3): Chân dung nhóm người nguy cơ cao bị chi phối mạnh mẽ bởi quy luật thời gian sinh học. Độ tuổi trung bình của nhóm này nằm ở phân khúc rất cao (Đồ thị 3: trên 58 tuổi), kết hợp với chỉ số khối cơ thể BMI ở ngưỡng thừa cân béo phì.

- + Sự đột biến từ hành vi ngoại sinh (Đồ thị 4): Biểu đồ bóc tách một đặc điểm chung cực kỳ quan trọng ở Cụm 1: Mặc dù tuổi đời còn tương đối trẻ (Đồ thị 3 chỉ quanh mức 42 tuổi), nhưng họ lại gánh chịu tỷ lệ mắc bệnh tim không hề nhỏ do sở hữu đặc điểm chung là lạm dụng thuốc lá ở mức cực đoan với lượng tiêu thụ vọt lên hơn 20 điếu/ngày (Đồ thị 4).

## 4.2. Phân nhóm bệnh nhân thành các mức độ nguy cơ bằng thuật toán K-Means

### 4.2.1. Mục tiêu phân tích

- Để trả lời cho câu hỏi: "*Có thể phân nhóm bệnh nhân thành các mức nguy cơ khác nhau dựa trên đặc điểm sức khỏe hay không?*", nghiên cứu cần chứng minh tính khả thi về mặt hình học của dữ liệu thông qua học máy không giám sát. Mục tiêu cốt lõi là đánh giá xem thuật toán có khả năng tự động phân mảnh quần thể bệnh nhân thành các nhóm riêng biệt có ranh giới toán học rõ ràng hay không. Việc phân nhóm này giúp cấu trúc hóa tập dữ liệu thô hỗn loạn thành các phân lớp rủi ro lũy tiến, làm cơ sở khoa học để thiết lập các hệ thống phân tầng nguy cơ y tế trong y học dự phòng.

### 4.2.2. Phương pháp thực hiện và Trực quan hóa dữ liệu

- Đề tài áp dụng Phương pháp đường cong khuỷu tay (Elbow Method) dựa trên chỉ số WCSS (Within-Cluster Sum of Squares) – tổng bình phương khoảng cách từ các điểm dữ liệu đến tâm cụm của chúng để tìm ra số lượng nhóm nguy cơ tối ưu (K).
- Công thức toán học của WCSS được định nghĩa:

$$WCSS = \sum_{k=1}^K \sum_{x \in C_k} ||x - \mu_k||^2$$

- Trong đó:

K: Số lượng cụm phân mảnh được thử nghiệm (từ 1 đến 10).


$C_k$ : Tập hợp các véc-tơ bệnh nhân thuộc cụm thứ k.

x: Tọa độ không gian đặc trưng sức khỏe đã chuẩn hóa Z-score của một bệnh nhân.

$\mu_k$ : Tọa độ tâm hình học (Centroid) đại diện của cụm thứ k.

- Sau khi xác định được K tối ưu, mô hình K-Means sẽ thực thi phân lớp và kết quả được trực quan hóa song song bằng đồ thị Elbow kết hợp biểu đồ đồ thị phân tán (Scatter Plot)

trên hai trục đặc trưng có hệ số tác động mạnh nhất là Tuổi (age) và Huyết áp trung bình (MAP).



Hình 4.2. Đồ thị xác định số cụm tối ưu và Không gian ranh giới phân tách K-Means

#### 4.2.3. Phân tích tri thức từ biểu đồ

- Kết quả thực nghiệm đồ thị và ma trận khoảng cách tại Hình 4.2 mang lại câu trả lời khẳng định cho Câu hỏi 2: Hoàn toàn có thể phân nhóm bệnh nhân thành các mức độ nguy cơ khác nhau một cách rõ rệt dựa trên đặc điểm sức khỏe thực thể và hành vi. \* Tri thức toán học từ đồ thị Elbow (Đồ thị 1): Đường cong WCSS sụt giảm rất nhanh từ  $K=1$  đến  $K=3$ , sau đó từ mốc  $K=3$  trở đi, tốc độ giảm bắt đầu bão hòa và tạo thành một đường thoải tuyến tính. Điểm gãy "khuỷu tay" xuất hiện rõ nét tại  $K=3$ . Điều này minh chứng rằng việc chia quần thể thành 3 nhóm nguy cơ là cấu trúc hình học tối ưu nhất, giúp cân bằng hoàn hảo giữa độ phức tạp của mô hình và độ tương đồng nội cụm.
- Sự hình thành các dải nguy cơ biệt lập (Đồ thị 2): Khi trực quan hóa các cụm lên không gian hai chiều giữa Tuổi (age) và Huyết áp trung bình (MAP), thuật toán K-Means đã tự động phân tầng bệnh nhân thành 3 mức độ rủi ro có ranh giới phân tách hình học cực kỳ rõ ràng:

+ Mức độ 1 - Vùng Nguy cơ thấp (Cụm 0 - Màu xanh): Tập trung dày đặc ở góc trái dưới của đồ thị. Đây là phân khúc an toàn nhất, dung hợp những

bệnh nhân có tuổi đời trẻ (32 - 45 tuổi) đi kèm mức nền huyết áp lý tưởng (<90mmHg).

- + Mức độ 2 - Vùng Rủi ro chuyển dịch do Lối sống (Cụm 1 - Màu cam):  
Năm trải dài ở phân khúc trung niên. Nhóm này có mức huyết áp và tuổi đời vừa phải nhưng bị thuật toán cô lập thành một dải nguy cơ riêng biệt do có sự bất thường từ mật độ tiêu thụ thuốc lá cực đoan và nhịp tim cao.
- + Mức độ 3 - Vùng Nguy cơ cao lâm sàng (Cụm 2 - Màu đỏ): Chiếm lĩnh hoàn toàn nửa trên và góc phải của đồ thị.

## CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

### 5.1. Kết quả đạt được

- Sau quá trình nghiên cứu, xây dựng và thực nghiệm, đề tài “Phân tích và dự đoán nguy cơ mắc bệnh tim” đã hoàn thành toàn diện các mục tiêu nghiên cứu và nhiệm vụ khoa học được đề ra ban đầu. Các kết quả cốt lõi đạt được bao gồm:
  - Xây dựng quy trình tiền xử lý dữ liệu chuẩn y khoa: Đề tài đã tiếp nhận và làm sạch thành công dữ liệu dịch tễ học từ bộ dữ liệu kinh điển Framingham Heart Study Dataset. Hệ thống mã nguồn đã xử lý triệt để hiện tượng dữ liệu khuyết thiếu bằng các kỹ thuật nội suy tối ưu (Mode Imputation cho biến phân loại, Median Imputation cho biến định lượng để khử nhiễu ngoại lệ); loại bỏ hiện tượng đa cộng tuyến bằng cách tổng hợp hai chỉ số huyết áp thành một đặc trưng sinh học duy nhất là Áp lực động mạch trung bình (MAP); và đưa không gian đặc trưng về cùng một quy mô hình học thông qua bộ lọc StandardScaler (Z-score).
  - Khai phá tri thức dịch tễ học và giải quyết các bài toán trực quan (EDA): Đề tài đã trả lời trọn vẹn 5 câu hỏi nghiên cứu thực chứng đặt ra ban đầu, bao gồm:
    - + Xác định xu hướng tăng trưởng dốc đứng của nguy cơ mắc bệnh tim theo tiến trình lão hóa, cô lập nhóm tuổi từ 60-70 là phân khúc rủi ro cao nhất.
    - + Bóc tách sự bất đối xứng về cán cân rủi ro giữa hai giới tính, định lượng tỷ lệ nguy cơ của Nam giới cao vượt trội so với Nữ giới.
    - + Xác định vị thế của các chỉ số sinh hóa cốt lõi, chứng minh MAP và glucose có mức độ tương quan thuận mạnh nhất đến biến cố tim mạch.
    - + Phát hiện thực trạng mất cân bằng dữ liệu nghiêm trọng với tỷ lệ lớp 85% (An toàn) và 15% (Nguy cơ), định hình chiến lược tối ưu mô hình toán học.
    - + Kiểm chứng thành công tính phân tách hình học của dữ liệu thông qua phân tích đồ thị hộp (Box plot).
  - Ứng dụng thành công Học máy giám sát (Supervised Learning): Đề tài đã thiết lập và huấn luyện mô hình phân loại dựa trên thuật toán rừng ngẫu nhiên (Random Forest Classifier). Mô hình đã học được các ranh giới quyết định phi tuyến tính phức tạp giữa các chỉ số lâm sàng và nguy cơ mắc bệnh, đồng thời

được cấu hình tối ưu để thúc đẩy chỉ số Recall (Độ nhạy) lên mức tối đa, giúp giảm thiểu rủi ro bỏ sót ca bệnh trong thực tế y tế.

- Ứng dụng thành công Học máy không giám sát (Unsupervised Learning): Thông qua thuật toán phân cụm K-Means Clustering kết hợp phương pháp đường cong khuỷu tay (Elbow Method), đề tài đã tự động phân mảnh quần thể bệnh nhân thành 3 phân khúc nguy cơ sức khỏe chiến lược (Nguy cơ thấp, Rủi ro do lối sống, Nguy cơ cao lâm sàng), mang lại cái nhìn toàn diện phục vụ y học dự phòng cá nhân hóa.

## 5.2. Hạn chế của đề tài

- Mặc dù đã đạt được nhiều kết quả thực nghiệm tích cực và có tính chính xác cao, đề tài vẫn tồn tại một số hạn chế khách quan nhất định cần được thẳng thắn nhìn nhận:
  - Tính đại diện của dữ liệu: Bộ dữ liệu Framingham được thu thập từ một quần thể dân cư đặc thù tại Mỹ từ nhiều năm trước, do đó các phân phối sinh học, thói quen dinh dưỡng và yếu tố di truyền có thể chưa hoàn toàn phản ánh chính xác đặc trưng dịch tễ học và thể trạng thực tế của người tiêu dùng y tế tại Việt Nam.
  - Thử thách từ hiện tượng mất cân bằng lớp: Sự chênh lệch lớn giữa số ca an toàn (85%) và ca rủi ro (15%) tạo ra rào cản toán học nhất định, khiến mô hình đôi khi gặp khó khăn trong việc thiết lập một ranh giới quyết định (Decision Boundary) hoàn hảo tuyệt đối trên tập kiểm thử.
  - Sự giới hạn của các thuộc tính đầu vào: Mô hình hiện tại mới chỉ tiếp cận các chỉ số lâm sàng cơ bản. Các yếu tố có ảnh hưởng mạnh mẽ đến hệ tim mạch hiện đại như:
    - + Tiền sử bệnh lý gia đình (Yếu tố di truyền sâu).
    - + Chế độ dinh dưỡng cụ thể và mức độ căng thẳng thần kinh (Stress).
    - + Tần suất vận động thể chất định lượng chi tiết.
    - + Các chỉ số sinh hóa chuyên sâu khác (như Triglyceride, HDL-C, LDL-C tách biệt).
    - + Chưa được tích hợp dồi dào trong tập dữ liệu tĩnh hiện tại.
  - Phạm vi thuật toán thử nghiệm: Nghiên cứu mới tập trung triển khai sâu hai thuật toán đại diện là Random Forest và K-Means. Việc chưa thực hiện mở rộng đối chiếu song song với nhiều họ thuật toán Boosting hay Mạng thần kinh nhân tạo khiến kết quả đánh giá hiệu năng tổng thể chưa đạt đến tính toàn diện tối đa.

### 5.3. Hướng phát triển trong tương lai

- Để nâng cao giá trị thực tiễn, tối ưu hóa năng lực tính toán và biến đề tài thành một công cụ ứng dụng lâm sàng mạnh mẽ, các hướng phát triển trong tương lai được hoạch định cụ thể như sau:
  - Bản địa hóa và mở rộng quy mô dữ liệu: Tiến hành liên kết, thu thập nguồn dữ liệu hồ sơ bệnh án điện tử (EHR) thực tế từ các bệnh viện, trung tâm tim mạch lớn tại Việt Nam nhằm tinh chỉnh và bản địa hóa mô hình AI phù hợp với thể trạng người Việt.
  - Áp dụng các kỹ thuật xử lý mất cân bằng lớp chuyên sâu: Nghiên cứu triển khai các thuật toán tái lấy mẫu nâng cao như SMOTE, ADASYN hoặc cấu hình các hàm phạt chi phí (Cost-Sensitive Learning) để tiếp tục đẩy cao năng lực nhận diện nhóm thiểu số (ca bệnh).
  - Mở rộng không gian thuật toán và tối ưu siêu tham số: Tiến hành thử nghiệm, so sánh hiệu năng toán học đồng thời với các thuật toán học máy tiên tiến dạng bảng (Tabular Data) bao gồm:
    - + XGBoost
    - + LightGBM
    - + CatBoost
    - + Mạng thần kinh nhân tạo đa tầng (Neural Networks)
    - + Thực hiện GridSearch CV chuyên sâu để bóc tách bộ tham số tối ưu nhất cho hệ thống.
  - Tích hợp kỹ thuật phân tích chuỗi thời gian và dữ liệu đa mô thức: Phát triển mô hình theo hướng Học sâu (Deep Learning) kết hợp xử lý dữ liệu thời gian thực từ các thiết bị đeo thông minh (Wearable IoT Devices) để theo dõi liên tục sự biến thiên nhịp tim, huyết áp của bệnh nhân theo từng giây.
  - Xây dựng Hệ thống hỗ trợ ra quyết định lâm sàng (CDSS): Đóng gói mô hình toán học thành một ứng dụng phần mềm hoàn chỉnh hoặc một API tích hợp chatbot AI thông minh để hỗ trợ các bác sĩ:
    - + Ước lượng định lượng xác suất rủi ro tim mạch của bệnh nhân trong 10 năm tới ngay sau khi có kết quả xét nghiệm máu.
    - + Tự động phân loại bệnh nhân vào các cụm nguy cơ để đưa ra khuyến cáo y tế và phác đồ phòng bệnh cá nhân hóa tự động.

## 5.4. Kết luận

- Trong bối cảnh chuyển đổi số y tế toàn cầu và sự trỗi dậy của mô hình Y tế thông minh (Smart Healthcare), việc ứng dụng Khoa học Dữ liệu và Học máy để chuyển dịch mô hình từ Chữa bệnh bị động sang Phòng bệnh chủ động đang trở thành xu hướng tất yếu mang tính chiến lược của nhân loại.
- Thông qua việc triển khai một quy trình khai phá dữ liệu toàn diện trên bộ dữ liệu Framingham Heart Study, đề tài “Phân tích và dự đoán nguy cơ mắc bệnh tim” đã chứng minh một cách thực chứng và định lượng mối liên hệ chặt chẽ giữa tiến trình lão hóa, giới tính cùng các hội chứng lâm sàng (huyết áp, đường huyết, mỡ máu) đối với sức khỏe tim mạch. Các kết quả thu được không chỉ khẳng định năng lực tự động hóa phân lớp chẩn đoán của mô hình Học máy giám sát (Random Forest) và tính khoa học trong phân tầng đối tượng của mô hình không giám sát (K-Means), mà còn mở ra một hướng tiếp cận mới mẻ, tin cậy cho công tác quản trị sức khỏe cộng đồng. Các hạn chế hiện tại của đề tài hoàn toàn có thể khắc phục bằng các giải pháp kỹ thuật nâng cao, đặt nền móng vững chắc cho các nghiên cứu tích hợp trí tuệ nhân tạo chuyên sâu hơn, góp phần giảm tải áp lực cho hệ thống y tế công và bảo vệ cuộc sống con người.

## TÀI LIỆU THAM KHẢO

- P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, *CRISP-DM 1.0: Step-by-step data mining guide*, Chicago: SPSS Inc., 2000. (Quy trình chuẩn cho khai phá dữ liệu y tế).
- W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter*, 3rd ed. Sebastopol, CA: O'Reilly Media, 2022. (Tài liệu nền tảng xử lý dữ liệu lâm sàng).
- F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. (Thư viện xây dựng mô hình Random Forest và K-Means).
- G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R and Python*, New York: Springer, 2023. (Lý thuyết phân loại và phân cụm dữ liệu).
- L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. (Thuật toán gốc dùng để dự đoán nguy cơ mắc bệnh tim).
- J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, pp. 281–297, 1967. (Thuật toán gốc dùng để phân cụm rủi ro sức khỏe K-Means).
- Mahmood, S. S., Levy, D., Vasan, R. S., & Wang, T. J., "The Framingham Heart Study and the epidemiology of cardiovascular diseases: a historical perspective," *The Lancet*, vol. 383, no. 9921, pp. 999-1008, 2014. (Bài báo khoa học gốc minh chứng về bộ dữ liệu Framingham).